

T.C.

İSTANBUL BEYKENT ÜNİVERSİTESİ

MESLEK YÜKSEKOKULU

BİLGİSAYAR TEKNOLOJİLERİ BÖLÜMÜ

BİLGİSAYAR PROGRAMCILIĞI PROGRAMI

YAPAY ZEKÂ DESTEKLİ AKILLI E-TİCARET VE OTOMASYON SİSTEMİ

Literatür Taraması ve Uygulamaları

Yönlendirilmiş Çalışma

Hazırlayan:

Görkem KAHYA

Efe Osmanhan GÜDÜCÜ

Emirhan ARDUÇ

T.C.

İSTANBUL BEYKENT ÜNİVERSİTESİ

MESLEK YÜKSEKOKULU

BİLGİSAYAR TEKNOLOJİLERİ BÖLÜMÜ

BİLGİSAYAR PROGRAMCILIĞI PROGRAMI

YAPAY ZEKÂ DESTEKLİ AKILLI E-TİCARET VE OTOMASYON SİSTEMİ

Literatür Taraması ve Uygulamaları

Yönlendirilmiş Çalışma

Hazırlayan:

Görkem KAHYA

Efe Osmanhan GÜDÜCÜ

Emirhan ARDUÇ

Öğrenci No:

……

Danışman:

Öğr. Gör. Firdevs DURNAGÖL

İSTANBUL, 2026

YEMİN METNİ

Yönlendirilmiş Çalışma olarak hazırladığımız "YAPAY ZEKÂ DESTEKLİ AKILLI E-TİCARET VE OTOMASYON SİSTEMİ: LİTERATÜR TARAMASI VE UYGULAMALARI" başlıklı bu çalışmanın, bilimsel ahlak ve geleneklere uygun şekilde tarafımızdan yazıldığını, yararlandığımız eserlerin tamamının kaynakça kısmında gösterildiğini ve çalışmamızda bu kaynaklara atıfta bulunulduğunu belirtir ve bunu onurumuzla doğrularız.

..... / ..... / 2026

İmza: _____

Öğrenci: Görkem KAHYA

İmza: _____

Öğrenci: Efe Osmanhan GÜDÜCÜ

İmza: _____

Öğrenci: Emirhan ARDUÇ

ÖZET

YAPAY ZEKÂ DESTEKLİ AKILLI E-TİCARET VE OTOMASYON SİSTEMİ: LİTERATÜR TARAMASI VE UYGULAMALARI

Bu çalışma, e-ticaret platformlarında kullanıcı deneyimini iyileştirmek amacıyla geliştirilen yapay zekâ ve makine öğrenmesi tabanlı kişiselleştirme ile öneri sistemlerini literatür çerçevesinde incelemektedir. Bilgi aşırı yüklenmesi sorununa karşı veri güdümlü çözüm yöntemlerinin önemi giderek artmaktadır.

Çalışmanın uygulama boyutunda HTML, CSS ve JavaScript kullanılarak tam işlevli bir e-ticaret ön yüzü tasarlanmış; PHP 8.1 ve RESTful API mimarisiyle backend altyapısı oluşturulmuştur. Hesabım, Favoriler ve Sepet sayfaları kimlik doğrulama, durum yönetimi ve veritabanı entegrasyonuyla birlikte yapılandırılmıştır. Sistem, hem web hem de mobil uygulamaya aynı backend üzerinden hizmet verecek şekilde kurgulanmıştır.

Literatürde içerik tabanlı filtreleme, işbirlikçi filtreleme ve hibrit yaklaşımlar incelenmiş; gömülüm teknikleri, derin sinir ağları ve duygu analizi yöntemleri ele alınmıştır. Sonuç olarak yapay zekâ destekli kişiselleştirmenin kullanıcı memnuniyetini artırmak ve rekabet avantajı sağlamak için stratejik bir araç olduğu ortaya konulmuştur.

Anahtar Kelimeler: E-Ticaret, Kişiselleştirme, Yapay Zekâ, Makine Öğrenmesi, Öneri Sistemleri, Derin Öğrenme, REST API, PHP, JWT.

KISALTMALAR

AI : Yapay Zekâ (Artificial Intelligence)

ALS : Dönüşümlü En Küçük Kareler (Alternating Least Squares)

API : Uygulama Programlama Arayüzü

CNN : Evrişimli Sinir Ağı (Convolutional Neural Network)

CORS : Çapraz Kaynak Paylaşımı (Cross-Origin Resource Sharing)

CSS : Basamaklı Stil Sayfaları (Cascading Style Sheets)

DL : Derin Öğrenme (Deep Learning)

GDPR : Genel Veri Koruma Tüzüğü (General Data Protection Regulation)

HTML : Hiper Metin İşaretleme Dili

HTTP : Köprü Metni Aktarım Protokolü (Hypertext Transfer Protocol)

JS : JavaScript

JSON : JavaScript Nesne Gösterimi (JavaScript Object Notation)

JWT : JSON Web Token

KVKK : Kişisel Verilerin Korunması Kanunu

LSTM : Uzun Kısa Süreli Bellek (Long Short-Term Memory)

MAE : Ortalama Mutlak Hata (Mean Absolute Error)

ML : Makine Öğrenmesi (Machine Learning)

NCF : Sinirsel İşbirlikçi Filtreleme (Neural Collaborative Filtering)

NoSQL : İlişkisel Olmayan Veritabanı (Not Only SQL)

PDO : PHP Veri Nesnesi (PHP Data Object)

PHP : Sunucu Taraflı Betik Dili (Hypertext Preprocessor)

REST : Temsili Durum Transferi (Representational State Transfer)

RMSE : Ortalama Karekök Hatası (Root Mean Squared Error)

RNN : Tekrarlayan Sinir Ağı (Recurrent Neural Network)

SGD : Stokastik Gradyan İnişi (Stochastic Gradient Descent)

TF-IDF : Terim Frekansı-Ters Belge Frekansı

UX : Kullanıcı Deneyimi (User Experience)

XAI : Açıklanabilir Yapay Zekâ (Explainable AI)

İÇİNDEKİLER

Sayfa No.

ÖZET .....

KISALTMALAR .....

İÇİNDEKİLER .....

GİRİŞ 9

Çalışmanın Amacı ve Kapsamı 9

Literatürün Önemi ve Akademik Katkı 9

Araştırma Soruları ve Yöntem 10

BİRİNCİ BÖLÜM — KURAMSAL ÇERÇEVE 11

1.1. Kişiselleştirme ve Bilgi Aşırı Yüklenmesi 11

1.2. Soğuk Başlama Problemi 11

1.3. Derin Sinir Ağları ve Duygu Analizi 12

1.4. E-Ticaretin Gelişimi ve Kullanıcı Deneyimi 13

1.5. Görsel Öneri Sistemleri ve Bilgisayar Görüsü 14

1.6. Hibrit Öneri Sistemleri 14

1.7. Sistem Mimarisi ve Veri Altyapısı 15

1.8. Etik ve Açıklanabilir Yapay Zekâ 16

1.9. Öneri Sistemlerinin Tarihsel Gelişimi 16

1.10. Matris Çarpanlarına Ayırma ve Gizli Faktör Modelleri 17

1.11. Benzerlik Ölçütleri 1

1.12. Öneri Sistemlerinde Değerlendirme Ölçütleri 15

İKİNCİ BÖLÜM — ALGORİTMALAR VE UYGULAMA 21

2.1. Makine Öğrenmesi Algoritmalarının Sınıflandırılması 21

2.2. Aktif Öğrenme ve Geri Bildirim Döngüsü 21

2.3. Veri Altyapısı ve Frontend Entegrasyonu 22

2.4. İçerik Tabanlı Filtrelemede TF-IDF ve Vektör Uzayı Modeli 23

2.5. İşbirlikçi Filtrelemede k-En Yakın Komşu Yaklaşımı 23

2.6. Derin Öğrenme Tabanlı Öneri Modelleri 24
2.7. Bölüm Değerlendirmesi 25
ÜÇÜNCÜ BÖLÜM — PROJE UYGULAMASI 26
3.1. Proje Genel Tanımı ve Kapsam 26
3.2. Frontend Geliştirme 26
3.3. Backend ve API Mimarisi 27
3.4. Veritabanı Tasarımı 28
3.5. Güvenlik ve Kimlik Doğrulama 28
3.6. Veritabanı İlişkileri ve Normalizasyon 29
3.7. Kişiselleştirme Modülünün Sisteme Entegrasyon Planı 30
3.8. Sonuçlar ve Değerlendirme 30
3.9. Gelecek Çalışmalar ve Öneriler 31
DÖRDÜNCÜ BÖLÜM — SİSTEM TASARIMI VE MİMARİ DETAYLAR 33
4.1. Yazılım Geliştirme Süreci 33
4.2. Kullanıcı Arayüzü Tasarım Kararları 33
4.3. API Tasarım Prensipleri 33
4.4. Performans Optimizasyonu 34
4.5. Test ve Doğrulama Süreci 34
4.6. Projenin Literatürle İlişkisi 35
4.7. Karşılaşılan Güçlükler ve Çözüm Yolları 35
4.8. Ölçeklenebilirlik ve Önbellekleme Stratejileri 35
4.9. Yapay Zekâ Modelinin Dağıtımı ve İzlenmesi 36
SONUÇ 38
KAYNAKÇA 40

GİRİŞ

Çalışmanın Amacı ve Kapsamı

Bu çalışma, e-ticaret platformlarında yapay zekâ destekli kişiselleştirme stratejilerini ve öneri sistemlerini incelemeyi amaçlamaktadır. Dijital ticaretin hızla büyümesiyle birlikte kullanıcılar, çevrim içi platformlarda çok sayıda ürün ve içerik arasında seçim yapmak zorunda kalmakta; bu durum literatürde "bilgi aşırı yüklenmesi" olarak bilinen sorunu gündeme getirmektedir (Resnick ve Varian, 1997). Söz konusu yüklenmeyi azaltmak için geliştirilen kişiselleştirilmiş öneri sistemleri, son yirmi yılda hem ticari hem de akademik bir araştırma alanı olarak hızla olgunlaşmıştır (Adomavicius ve Tuzhilin, 2005; Ricci vd., 2015).

Çalışmada, içerik tabanlı filtreleme, işbirlikçi filtreleme, hibrit yaklaşımlar ve derin öğrenme tabanlı modeller bir arada ele alınmakta; bu yöntemlerin teorik temelleri ile birlikte gerçek bir e-ticaret altyapısına nasıl uyarlanabileceği değerlendirilmektedir. Kullanıcı davranışlarının analizi, gömülüm (embedding) teknikleri ve duygu analizi gibi ileri düzey yaklaşımların öneri sistemlerinde nasıl konumlandığı araştırılmıştır.

Çalışmanın pratik boyutunda MODAICA adlı tam işlevli bir e-ticaret sitesi geliştirilmiştir. Site; HTML, CSS ve JavaScript ile oluşturulan duyarlı bir ön yüz, PHP 8.1 ile yazılmış RESTful API tabanlı bir backend, JWT tabanlı kimlik doğrulama sistemi ve MySQL veritabanından oluşmaktadır. Hesabım, Favoriler ve Sepet sayfaları, backend ile gerçek zamanlı iletişim kurarak kullanıcı bazlı veri yönetimi yapacak biçimde yapılandırılmıştır.

Literatürün Önemi ve Akademik Katkı

Öneri sistemleri alanındaki akademik çalışmalar, bilgi aşırı yüklenmesini azaltan, kullanıcı davranışlarını analiz eden ve veri temelli karar mekanizmaları geliştiren yaklaşımlar sunmaktadır (Goldberg vd., 1992; Resnick ve Varian, 1997). Alan; 1990'lı yıllarda kullanıcı tabanlı işbirlikçi filtreleme ile başlayıp 2000'lerde ürün-ürün benzerliğine dayalı yöntemlere (Sarwar vd., 2001; Linden vd., 2003), 2010'larda ise gizli faktör modellerine (Koren vd., 2009) ve derin sinir ağı tabanlı yaklaşımlara (He vd., 2017; Zhang vd., 2019) doğru evrilmiştir.

Bu çalışmanın akademik katkısı, farklı makine öğrenmesi tekniklerinin ve sistem mimarilerinin e-ticaret platformlarındaki uygulanabilirliğini bir arada sunması, etik ve şeffaflık boyutlarını literatür ışığında değerlendirmesidir. Pratik katkı açısından ise geliştirilen MODAICA projesinin hem web hem de gelecekte eklenecek mobil uygulamaya aynı PHP backend üzerinden hizmet verecek şekilde kurgulanması; durumsuz (stateless) ve katmanlı bir mimari aracılığıyla bu esnekliğin somut olarak gösterilmesi önemli bir çıktı olarak değerlendirilmektedir (Fielding, 2000).

Araştırma Soruları ve Yöntem

Çalışma, e-ticaret öneri sistemleri bağlamında üç temel araştırma sorusuna yanıt aramaktadır:

- **Soru 1:** İçerik tabanlı, işbirlikçi ve hibrit filtreleme yöntemleri arasındaki temel farklar ve bunların güçlü-zayıf yönleri nelerdir?
- **Soru 2:** Bilgi aşırı yüklenmesi, veri seyrekliği ve soğuk başlama gibi temel problemler hangi yaklaşımlarla hafifletilebilir?
- **Soru 3:** Literatürde tanımlanan bu yöntemler MODAICA gibi gerçek bir e-ticaret altyapısına nasıl uyarlanabilir?

Bu sorular, hem kuramsal bir literatür taraması hem de uygulamalı bir sistem geliştirme yöntemi birlikte kullanılarak ele alınmıştır. Yöntem olarak çalışmada nitel bir literatür incelemesi ile tasarım temelli bir geliştirme süreci birleştirilmiştir. Öneri sistemleri alanının temel kaynakları (Goldberg vd., 1992; Resnick ve Varian, 1997; Adomavicius ve Tuzhilin, 2005) ile güncel derin öğrenme yaklaşımları (He vd., 2017; Zhang vd., 2019) incelenmiş; elde edilen kavramsal çerçeve MODAICA projesinin mimari kararlarına temel oluşturmuştur.

Çalışma dört bölümden oluşmaktadır. Birinci bölüm, kuramsal çerçeveyi ve öneri sistemlerinin matematiksel temellerini ele almaktadır. İkinci bölümde algoritmalar ve değerlendirme ölçütleri ayrıntılı biçimde incelenmektedir. Üçüncü bölüm, MODAICA projesinin uygulama detaylarını sunmakta; dördüncü bölüm ise sistem tasarımı ve mimari kararları kapsamaktadır. Sonuç bölümünde bulgular özetlenmekte ve gelecek çalışmalara yönelik öneriler sunulmaktadır.

BİRİNCİ BÖLÜM

KURAMSAL ÇERÇEVE

1.1. Kişiselleştirme ve Bilgi Aşırı Yüklenmesi

E-ticaret platformlarında kullanıcı deneyimini iyileştirmenin en kritik yaklaşımlarından biri kişiselleştirme sürecidir. Kişiselleştirme; kullanıcının geçmiş davranışları, tercihleri ve etkileşimleri temel alınarak sunulan içerik ve ürünlerin her bireye özgü hâle getirilmesi olarak tanımlanır (Adomavicius ve Tuzhilin, 2005). Bu süreç, kullanıcıların platform içinde ilgi alanlarına en uygun ürünleri hızla bulabilmesini sağlar; hem müşteri memnuniyetini hem de satış performansını artırır (Schafer vd., 1999).

Ancak e-ticaret ortamları, geniş ürün katalogları nedeniyle bilgi aşırı yüklenmesi problemiyle karşı karşıyadır. Resnick ve Varian (1997), öneri sistemlerini esas olarak bu yüklenmeyi azaltmaya yönelik bir bilgi filtreleme aracı olarak tanımlamaktadır. Tüketiciye sunulan seçenek bolluğu karar verme sürecini zorlaştırır ve "karar yorgunluğu" olarak adlandırılan duruma yol açar. Bu bağlamda kişiselleştirme yalnızca öneri üretmekle kalmaz; bilgi yükünü yöneterek kullanıcıya en anlamlı seçenekleri sunar.

Günümüz e-ticaret platformları, kişiselleştirmeyi hem içerik tabanlı hem de işbirlikçi filtreleme yöntemlerini hibrit biçimde kullanarak gerçekleştirmektedir (Burke, 2002). Bu kombinasyon sistemin hem yeni hem de mevcut kullanıcılar için yüksek isabetli öneriler üretmesine olanak tanır. Kişiselleştirme stratejisinin başarısı; ürün katalogu büyüklüğü, kullanıcı kitlesinin homojenliği ve sistemin topladığı etkileşim verilerinin zenginliği gibi etkenlere bağlıdır (Aggarwal, 2016).

1.2. Soğuk Başlama Problemi

Kişiselleştirilmiş öneri sistemlerinin karşılaştığı temel teknik zorluklardan biri "soğuk başlama" (cold-start) problemidir. Bu problem, sistemin yeni bir kullanıcı veya yeni bir ürün hakkında yeterli veri bulunmadığında doğru öneriler üretememesi olarak tanımlanır (Adomavicius ve Tuzhilin, 2005; Ricci vd., 2015). Platforma ilk kez katılan bir kullanıcıya öneri sunmak ya da yeni eklenen bir ürünün hangi kullanıcılara yönelik olduğunu tahmin etmek, veri yetersizliği nedeniyle güçleşmektedir.

Literatürde soğuk başlama probleminin üç ana biçimi tanımlanmaktadır: (i) yeni kullanıcı problemi, (ii) yeni ürün problemi, (iii) yeni topluluk problemi. Bu sorunu çözmek için literatürde geliştirilen başlıca yaklaşımlar şunlardır:

- **Kullanıcı ve ürün profili tabanlı yaklaşımlar:** Kayıt sırasında alınan demografik bilgiler ve tercih anketleri aracılığıyla erken dönem öneriler oluşturulur. Bu yaklaşımlar özellikle yeni kullanıcı problemine karşı etkilidir (Pazzani ve Billsus, 2007).
- **Hibrit sistemler:** İçerik tabanlı ve işbirlikçi filtreleme yöntemleri bir arada kullanılarak hem ürün özellikleri hem de topluluk davranışları dikkate alınır. Burke (2002), hibrit yaklaşımların soğuk başlama dayanıklılığı sağladığını ayrıntılı biçimde göstermiştir.
- **Derin öğrenme tabanlı çözümler:** Görsel odaklı platformlarda derin sinir ağları kullanılarak veri yetersizliği durumunda bile anlamlı öneriler üretilebilmektedir (Zhang vd., 2019).
- **Popülerlik tabanlı geçici öneriler:** Sistem, kullanıcıya yeterli veri biriktirinceye kadar geçici olarak en çok satan veya en çok beğenilen ürünleri sunabilir; bu yaklaşım minimal ama etkili bir başlangıç stratejisi sağlar.

MODAICA platformunda kullanıcıların kayıt aşamasında alınan tercih bilgileri ve sipariş sonrası birikecek davranış verileri, ileride bu katmanlı stratejinin uygulanabilmesi için uygun bir altyapı oluşturmaktadır.

1.3. Derin Sinir Ağları ve Duygu Analizi

E-ticaret platformlarında kullanıcı davranışlarını analiz etmek ve kişiselleştirilmiş öneriler sunmak için derin sinir ağları (DNN) giderek yaygınlaşmaktadır. Zhang vd. (2019) tarafından yapılan kapsamlı derlemede, derin öğrenme tabanlı öneri sistemlerinin yalnızca son beş yılda yayımlanan binlerce çalışmaya konu olduğu ve geleneksel matris çarpanlarına ayırma yaklaşımlarına kıyasla anlamlı doğruluk artışı sağladığı raporlanmıştır.

Derin sinir ağları, karmaşık ve yüksek boyutlu verilerden anlamlı örüntüler çıkarabilme yeteneğine sahiptir. Bu özellik moda ve giyim sektöründe ürünlerin renk, doku, desen ve biçim gibi görsel niteliklerini analiz ederek kullanıcıya uygun öneriler sunmada kritik bir avantaj sağlar. Derin öğrenme modelleri, kullanıcıların önceki satın alma ve tıklama geçmişlerinden öğrenerek yeni ürünler için bile doğru tahminlerde bulunabilmektedir. Bu süreç, ürün ve kullanıcı verilerinin gömülüm (embedding)

teknikleriyle düşük boyutlu vektörlere dönüştürülmesi sayesinde daha verimli hâle gelir (He vd., 2017).

Duygu analizi, kullanıcı yorumlarındaki olumlu veya olumsuz tonları doğal dil işleme yöntemleriyle değerlendirerek sistemin önerilerini şekillendirir. Bir kullanıcı bir ürün hakkında olumsuz yorum yaptıysa sistem, benzer ürünleri önerirken bu olumsuz eğilimi dikkate alır ve böylece daha bağlamsal öneriler sağlanır. Duygu analizinin öneri sistemleriyle birleştirilmesi, özellikle satış öncesi karar verme aşamasında kullanıcı güvenini artıran önemli bir bileşendir (Aggarwal, 2016).

1.4. E-Ticaretin Gelişimi ve Kullanıcı Deneyimi

E-ticaret, fiziksel mağazacılık döneminden günümüz dijital ticaret ekosistemine doğru hızlı bir evrim geçirmiştir. İnternetin yaygınlaşması, çevrim içi mağazaların artması ve mobil cihaz kullanımının yükselmesi ticareti dijital platformlara taşımış ve tüketicilere her yerden erişilebilir geniş bir ürün yelpazesi sunmuştur. Bu evrimin erken döneminde, Schafer vd. (1999), öneri sistemlerinin e-ticaret platformlarında satışları artırma, müşteri sadakatini güçlendirme ve müşteri çapraz satışı sağlama biçimindeki üç temel ekonomik etkisini sistematik olarak tanımlamıştır.

Kullanıcı deneyimi (UX), e-ticarette yalnızca tasarım ve navigasyonla sınırlı kalmayıp kişiselleştirme ve öneri sistemlerinin etkinliğiyle de doğrudan ilişkilidir. Platformlar kullanıcıların geçmiş davranışlarını, satın alma eğilimlerini ve göz atma verilerini analiz ederek her kullanıcıya özgü içerikler sunmayı hedeflemektedir. Kullanıcı deneyiminin niceliksel ölçütleri arasında oturum süresi, sepete ekleme oranı ve dönüşüm oranı gibi göstergeler yer almaktadır; bu ölçütlerin tümü kişiselleştirme kalitesiyle doğrudan korelasyon göstermektedir (Ricci vd., 2015).

E-ticaret deneyimi yalnızca geçmiş verilere dayalı değildir; kullanıcının anlık bağlamı, konumu ve ruh hali de öneri sürecinde dikkate alınabilir. Adomavicius ve Tuzhilin (2005), bağlam duyarlı öneri sistemlerinin (context-aware recommender systems) klasik iki boyutlu (kullanıcı-ürün) modelin ötesine geçerek zaman, yer, cihaz ve sosyal bağlam gibi ek boyutları sürece dâhil ettiğini göstermiştir. Bağlam duyarlı yaklaşım, kullanıcıya daha proaktif öneriler sunulmasını sağlar: mevsim, coğrafi konum veya günün saatine bağlı olarak farklı ürün önerileri sunmak, kullanıcı deneyimini kişiselleştirmenin etkili bir yolu olarak öne çıkmaktadır.

1.5. Görsel Öneri Sistemleri ve Bilgisayar Görüsü

Moda ve giyim sektöründe ürünlerin görsel özellikleri karar verme sürecinde kritik bir rol oynamaktadır. Bu nedenle görsel tabanlı öneri sistemleri, kullanıcıların tercihlerini daha doğru tahmin edebilmek için önemli bir araç hâline gelmiştir. Zhang vd. (2019), evrişimli sinir ağlarının (CNN) öneri sistemlerinde özellikle görsel ağırlıklı ürün kataloglarında öznitelik çıkarımı için yaygın biçimde kullanıldığını ve klasik metin tabanlı yaklaşımlara kıyasla daha zengin temsiller ürettiğini raporlamaktadır.

Bu sistemler ürün görsellerini evrişimli sinir ağları aracılığıyla analiz ederek ürünler arasındaki görsel benzerlikleri belirler. Kullanıcıların sepet veya beğeni geçmişiyle birleştirildiğinde öneri sistemi hem görsel hem de davranışsal verileri entegre ederek daha kişiselleştirilmiş öneriler sunar. McAuley vd. (2015), görsel benzerlik temelli öneri yaklaşımlarının özellikle "birlikte alınan ürünler" tahmininde geleneksel yöntemlerden üstün olduğunu göstermiştir.

Bilgisayar görüsü tabanlı öneri sürecinin temel bileşenleri şunlardır:

- **CNN Modeli:** Ürün görsellerinden renk, desen ve doku gibi özellikleri otomatik olarak çıkarır.
- **Embedding:** Ürünlerin görsel özelliklerini sayısal vektörlere dönüştürerek benzer ürünlerin birbirine yakın konumlanmasını sağlar.
- **Kombin Öneri:** Kullanıcının seçtiği bir ürünle renk ve stil açısından uyumlu diğer ürünler otomatik olarak gruplandırılır.
- **Duygu Analizi Desteği:** Kullanıcı yorumlarının analiz edilerek öneri ağırlıklarının dinamik güncellenmesi sağlanır.

MODAICA projesinin mevcut kapsamında görsel öneri modülü uygulanmamış olmakla birlikte, sistemin veri altyapısı bu tür bir modülün ileride entegre edilmesine olanak tanıyacak biçimde tasarlanmıştır.

1.6. Hibrit Öneri Sistemleri

E-ticaret platformlarında tek bir öneri yöntemine dayalı sistemler genellikle sınırlı başarı göstermektedir. Bu nedenle iki veya daha fazla yöntemin bir araya getirildiği hibrit öneri sistemleri literatürde öne çıkmaktadır. Burke (2002), hibrit yaklaşımları yedi farklı

kategoride sınıflandırarak alana sistematik bir taksonomi kazandırmıştır; bu sınıflandırma günümüzde de hibrit sistem tasarımının temel referansı olarak kabul edilmektedir.

Hibrit sistemlerin üç temel strateji ile modellendiği görülmektedir (Burke, 2002):

- **Ağırlıklı Kombinasyon (Weighted):** Her öneri türüne belirli ağırlıklar verilir ve sonuçlar birleştirilir. Ağırlıklar sabit veya öğrenilebilir olabilir.
- **Dönüşümlü Kombinasyon (Switching):** Sistemin hangi öneri yöntemini kullanacağı kullanıcı veya ürün durumuna göre belirlenir; örneğin yeni kullanıcılarda içerik tabanlı, yerleşik kullanıcılarda işbirlikçi yöntem kullanılır.
- **Entegrasyon Tabanlı Yaklaşım (Feature Combination / Meta-Level):** Kullanıcı ve ürün verileri tek bir modelin girişinde birleştirilir; öneri sonuçları tek bir algoritma tarafından üretilir.

Hibrit yaklaşımların en önemli avantajı, tek bir yöntemin zayıf yönlerinin başka bir yöntemle dengelenebilmesidir. Örneğin işbirlikçi filtrelemenin soğuk başlama sorunu, içerik tabanlı bileşenle hafifletilirken; içerik tabanlı yaklaşımın aşırı uzmanlaşma eğilimi, işbirlikçi bileşenle dengelenir (Burke, 2002; Ricci vd., 2015).

1.7. Sistem Mimarisi ve Veri Altyapısı

Modern e-ticaret platformlarında yapay zekâ ve öneri sistemlerinin başarısı, güçlü bir sistem mimarisi ve verimli veri altyapısına bağlıdır. Aggarwal (2016), öneri sistemlerinin endüstriyel uygulamalarında veri toplama, model eğitimi ve çevrim içi çıkarsama aşamalarının açıkça ayrıştırılmış bir mimariyle yönetilmesinin sistemin sürdürülebilirliği için kritik olduğunu vurgulamaktadır.

E-ticaret sistemleri genel olarak üç ana katmandan oluşur:

- **Veri Katmanı:** Kullanıcı etkileşimleri, tıklama geçmişi, ürün görselleri ve yorumlar burada toplanır ve ilişkisel ya da NoSQL veritabanlarıyla depolanır. Yüksek hacimli etkileşim verileri için olay tabanlı (event-driven) toplama stratejileri tercih edilir.
- **Model Katmanı:** Veriler makine öğrenmesi ve derin öğrenme modellerine beslenir. Çevrim dışı eğitim ve çevrim içi çıkarsama süreçleri bu katmanda yönetilir. Model katmanı genellikle uygulama katmanından ayrı bir servis olarak konuşlandırılır.

- **Uygulama Katmanı:** Modelden çıkan öneriler API'ler aracılığıyla ön yüze iletilir ve kullanıcı etkileşimleri geri bildirim döngüsüne beslenir. Bu katman, durumsuz (stateless) REST API mimarisini benimsediğinde yatay ölçeklenmeye uygun hâle gelir (Fielding, 2000).

MODAICA mimarisinde veri katmanı MySQL veritabanı, uygulama katmanı ise PHP RESTful API ve JavaScript ön yüzünden oluşmaktadır. Model katmanı, projenin mevcut sürümünde yer almamakla birlikte, mevcut API yapısına ileride entegre edilebilecek biçimde tasarlanmıştır.

1.8. Etik ve Açıklanabilir Yapay Zekâ

E-ticaret platformlarında kişiselleştirme ve öneri sistemlerinin başarısı yalnızca algoritmaların doğruluğuna bağlı değildir; etik veri kullanımı ve şeffaflık da kritik öneme sahiptir. Kullanıcılar daha iyi öneriler almak için verilerini paylaşmak isterken aynı zamanda gizliliklerinin korunmasını talep eder. Ricci vd. (2015), öneri sistemlerinin ticari başarısının uzun vadede kullanıcı güveniyle doğrudan ilişkili olduğunu ve gizlilik ihlallerinin platform sadakatini kalıcı biçimde zedelediğini vurgulamaktadır.

Açıklanabilir Yapay Zekâ (XAI), öneri sistemlerinin karar mekanizmalarını kullanıcıya veya yöneticilere açıklayabilen modeller geliştirmeyi amaçlar. "Bu ürün size neden önerildi?" sorusuna anlamlı bir cevap verebilen sistemler, kullanıcı güvenini ve dönüşüm oranlarını artırmaktadır. XAI yaklaşımları arasında özellik önemine dayalı açıklamalar, benzerlik tabanlı açıklamalar ve doğal dilde gerekçe üretimi gibi yöntemler yer almaktadır.

Avrupa Birliği'nin Genel Veri Koruma Tüzüğü (GDPR) ve Türkiye'nin Kişisel Verilerin Korunması Kanunu (KVKK), veri işleme süreçlerinde kullanıcı rızasının şeffaf ve bilinçli olmasını şart koşar. Bu düzenlemeler özellikle profil çıkarımı (profiling) ve otomatik karar verme süreçlerinde kullanıcılara itiraz hakkı tanımaktadır. MODAICA gibi Türkiye'deki kullanıcılara hizmet eden bir platformun KVKK uyumluluğu, hem yasal bir gereklilik hem de kullanıcı güveninin korunması açısından stratejik öneme sahiptir.

1.9. Öneri Sistemlerinin Tarihsel Gelişimi

Öneri sistemleri kavramının kökeni 1990'lı yılların başına dayanmaktadır. Bilgi filtreleme alanındaki ilk önemli çalışmalardan biri olan Tapestry sisteminde,

kullanıcıların belgeler hakkındaki tepkilerine dayalı bir filtreleme yaklaşımı önerilmiş ve literatüre "işbirlikçi filtreleme" (collaborative filtering) terimi kazandırılmıştır (Goldberg vd., 1992). İlerleyen yıllarda Resnick ve Varian (1997), öneri sistemlerini ayrı bir araştırma alanı olarak tanımlamış ve sistemlerin kullanıcıların bilgi yükünü azaltmadaki rolünü vurgulamıştır.

2000'li yıllarla birlikte öneri sistemleri ticari platformlarda yaygın biçimde uygulanmaya başlanmıştır. Büyük ölçekli e-ticaret ortamlarında milyonlarca kullanıcı ve ürün için ölçeklenebilir çözümler gerektiğinden, kullanıcı tabanlı yaklaşımlar yerine ürün-ürün ilişkilerine dayalı öğe tabanlı işbirlikçi filtreleme öne çıkmıştır (Sarwar vd., 2001). Bu dönemde geliştirilen öğeden öğeye işbirlikçi filtreleme yöntemi, çevrim içi perakende sektöründe geniş kullanım bulmuş; Amazon'un öneri motorunda hayata geçirilen yaklaşım bu alandaki en bilinen başarı örneklerinden biri olmuştur (Linden vd., 2003).

Öneri sistemlerinin gelişiminde bir dönüm noktası, 2006-2009 yılları arasında düzenlenen Netflix Ödülü yarışmasıdır. Bu yarışma, gizli faktör modellerine dayanan matris çarpanlarına ayırma tekniklerinin klasik en yakın komşu yöntemlerine kıyasla daha başarılı sonuçlar verdiğini ortaya koymuştur (Koren vd., 2009). Sonraki yıllarda ise derin öğrenme tabanlı yaklaşımlar alana hâkim olmaya başlamış (He vd., 2017; Zhang vd., 2019); öneri sistemlerinin sınıflandırılması ve gelecekteki yönelimleri üzerine yapılan kapsamlı değerlendirmeler, alanın içerik tabanlı, işbirlikçi ve hibrit olmak üzere üç ana eksende geliştiğini göstermiştir (Adomavicius ve Tuzhilin, 2005; Su ve Khoshgoftaar, 2009).

1.10. Matris Çarpanlarına Ayırma ve Gizli Faktör Modelleri

Matris çarpanlarına ayırma (matrix factorization), kullanıcı-ürün etkileşim matrisini düşük boyutlu iki matrisin çarpımı olarak ifade eden bir gizli faktör modelidir. Bu yaklaşımda her kullanıcı ve her ürün, ortak bir gizli faktör uzayında bir vektörle temsil edilir. Bir kullanıcının bir ürüne vereceği tahmini puan, kullanıcı vektörü ile ürün vektörünün iç çarpımı olarak hesaplanır (Koren vd., 2009):

$$\hat{r}_{ui} = q_i^T \cdot p_u$$

Bu eşitlikte p_u kullanıcının gizli faktör vektörünü, q_i ise ürünün gizli faktör vektörünü ifade etmektedir. Model, gözlemlenen puanlar üzerindeki tahmin hatasını en

aza indirecek biçimde, düzenlileştirme (regularization) terimi eklenerek eğitilir. Amaç fonksiyonu genellikle aşağıdaki biçimde tanımlanır:

$$min \Sigma (r_{ui} - q_i^T p_u)^2 + \lambda (\|q_i\|^2 + \|p_u\|^2)$$

Eğitim sürecinde genellikle Stokastik Gradyan İnişi (SGD) veya Dönüşümlü En Küçük Kareler (ALS) yöntemleri kullanılır. Düzenlileştirme terimi (λ ile kontrol edilir), modelin eğitim verisine aşırı uyum sağlamasını (overfitting) önleyerek yeni kullanıcılar üzerinde de genelleme yapmasına olanak tanır (Koren vd., 2009).

Matris çarpanlarına ayırma yöntemi, örtük geri bildirim (implicit feedback), zamansal etkiler ve güven düzeyleri gibi ek bilgilerin modele dâhil edilmesine de imkân tanıdığı için e-ticaret bağlamında esnek bir temel sağlar. Örtük geri bildirim modellerinde tıklama, sepete ekleme ve satın alma gibi sinyaller, açık puanlamanın yokluğunda gizli faktör eğitimi için temel veri kaynağı hâline gelir (Hu vd., 2008). MODAICA gibi sipariş ve favori verilerini biriktiren bir platformda bu veriler, gelecekte örtük geri bildirim sinyalleri olarak böyle bir modele beslenebilir.

1.11. Benzerlik Ölçütleri

İşbirlikçi filtreleme ve içerik tabanlı yöntemlerin temelinde, kullanıcılar veya ürünler arasındaki benzerliğin sayısal olarak ölçülmesi yatar. Literatürde en yaygın kullanılan benzerlik ölçütlerinden biri, iki vektör arasındaki açının kosinüsünü temel alan kosinüs benzerliğidir (Sarwar vd., 2001):

$$benzerlik(u, v) = (\Sigma r_{ui} \cdot r_{vi}) / (\sqrt{(\Sigma r_{ui}^2)} \cdot \sqrt{(\Sigma r_{vi}^2)})$$

Bir diğer yaygın ölçüt, kullanıcıların ortalama puanlama eğilimlerindeki farklılıkları hesaba katan Pearson korelasyon katsayısıdır. Bu ölçüt, bir kullanıcının genel olarak yüksek ya da düşük puan verme eğilimini ortadan kaldırarak daha adil bir karşılaştırma sağlar (Ricci vd., 2015). İkili (var/yok) verilerle çalışılan durumlarda ise iki küme arasındaki örtüşmeyi ölçen Jaccard benzerlik katsayısı tercih edilmektedir. Kullanılacak ölçütün seçimi, verinin yapısına ve uygulamanın gereksinimlerine göre değişir:

- **Kosinüs benzerliği:** Vektörlerin yönünü dikkate alır; puan büyüklüğünden çok örüntü benzerliğine duyarlıdır. Yüksek boyutlu seyrek vektörlerde tercih edilir.

- **Pearson korelasyonu:** Kullanıcıların ortalama puanlama farklılıklarını normalize eder; açık puanlama verisi olduğunda etkilidir.
- **Jaccard katsayısı:** Favori veya satın alma gibi ikili etkileşim verilerinde örtüşmeyi ölçer; örtük geri bildirim için uygundur.

MODAICA platformunda biriken favori, sepet ve sipariş verileri ikili nitelikte olduğundan, ileride uygulanacak bir benzerlik tabanlı öneri modülünde Jaccard ve kosinüs ölçütlerinin birlikte değerlendirilmesi uygun bir başlangıç stratejisi olarak görünmektedir.

1.12. Öneri Sistemlerinde Değerlendirme Ölçütleri

Bir öneri sisteminin başarısı, ürettiği önerilerin ne kadar isabetli olduğunun nesnel ölçütlerle değerlendirilmesini gerektirir. Ricci vd. (2015) ve Su ve Khoshgoftaar (2009), öneri sistemlerinde değerlendirme ölçütlerini iki ana grupta sınıflandırmaktadır: tahmin doğruluğunu ölçen ölçütler ile sıralama ve sınıflandırma başarısını ölçen ölçütler.

Puan tahmininin başarısı genellikle Ortalama Karekök Hatası (RMSE) ve Ortalama Mutlak Hata (MAE) ile ölçülür:

$$RMSE = \sqrt{((1/n) \cdot \Sigma (r_{ui} - \hat{r}_{ui})^2)} \qquad MAE = (1/n) \cdot \Sigma |r_{ui} - \hat{r}_{ui}|$$

Önerilerin ilgili olup olmadığını değerlendiren sınıflandırma temelli ölçütler ise kesinlik (precision) ve duyarlılık (recall) üzerine kuruludur. Kesinlik, önerilen ürünlerin ne kadarının gerçekten ilgili olduğunu; duyarlılık ise ilgili ürünlerin ne kadarının önerilebildiğini gösterir. Bu iki ölçütün dengelenmesi için harmonik ortalamaları olan F1 skoru kullanılır:

$$Kesinlik = |İlgili \cap Önerilen| \,/\, |Önerilen| \qquad Duyarlılık = |İlgili \cap Önerilen| \,/\, |İlgili|$$

$$F1 = 2 \cdot (Kesinlik \cdot Duyarlılık) \,/\, (Kesinlik + Duyarlılık)$$

Önerilerin sıralamasının kalitesini değerlendirmek için ise sıralamaya duyarlı ölçütler kullanılır (örneğin Mean Average Precision, MAP ve Normalized Discounted Cumulative Gain, NDCG). Bu ölçütler, ilgili ürünlerin öneri listesinin üst sıralarında yer almasını ödüllendirir. Değerlendirme ölçütünün seçimi sistemin amacına bağlıdır: puan tahmini odaklı sistemlerde RMSE/MAE, ilk-N öneri listesi üreten sistemlerde ise kesinlik, duyarlılık ve sıralama temelli ölçütler ön plana çıkar (Ricci vd., 2015).

Doğruluk ölçütlerinin yanı sıra son yıllarda çeşitlilik (diversity), yenilik (novelty), kapsama (coverage) ve serendipity (beklenmedik isabetli öneri) gibi kullanıcı deneyimi odaklı ölçütlerin de önem kazandığı görülmektedir. Bu ölçütler özellikle aşırı uzmanlaşma sorununu hafifletmek isteyen sistemlerde rehber niteliğindedir.

İKİNCİ BÖLÜM

ALGORİTMALAR VE UYGULAMA

2.1. Makine Öğrenmesi Algoritmalarının Sınıflandırılması

Yapay zekâ destekli öneri sistemlerinde kullanılan makine öğrenmesi algoritmaları, kullanım amacına ve veriye yaklaşım biçimine göre üç ana kategoride sınıflandırılmaktadır (Adomavicius ve Tuzhilin, 2005; Aggarwal, 2016). Bu sınıflandırma, sistem mimarisinin tasarımında ve uygun algoritmanın seçilmesinde rehber niteliğindedir.

İçerik Tabanlı Filtreleme: İçerik tabanlı filtreleme, kullanıcının geçmişte beğendiği ürünlere dayalı olarak yeni ürün önerileri sunar (Pazzani ve Billsus, 2007). Sistem, ürünlerin renk, desen, stil veya kategori gibi özelliklerini analiz eder ve benzer özelliklere sahip ürünleri önerir. Bu yöntem özellikle yeni ürünler eklendiğinde avantaj sağlar; zira kullanıcının geçmiş tercihlerine bakılarak öneri yapılır ve ürünün popülerliği belirleyici olmaz. Moda kombinasyonlarında bu yaklaşım, bir elbiseyi beğenen kullanıcıya renk ve stil açısından uyumlu ayakkabı veya çanta önerilmesini mümkün kılar.

İşbirlikçi Filtreleme: İşbirlikçi filtreleme, kullanıcıların topluluk davranışlarını analiz ederek öneri üretir (Sarwar vd., 2001; Su ve Khoshgoftaar, 2009). Benzer zevklere sahip kullanıcıların tercihleri karşılaştırılır; bir kullanıcının henüz görmediği ürünler, ona benzer kullanıcıların ilgi gösterdiği ürünler üzerinden tahmin edilir. Bu yaklaşım kullanıcıların tıklama, beğeni veya satın alma davranışları üzerinden öğrenir. Ancak yeni kullanıcılar veya yeni ürünler için veri eksikliği problemi göz önünde bulundurulmalıdır.

Derin Öğrenme ve Modern Mimariler: Derin öğrenme tabanlı algoritmalar, geleneksel yöntemlerin ötesine geçerek karmaşık ve bağlamsal ilişkileri modellemeye olanak tanır (He vd., 2017; Zhang vd., 2019). Kullanıcıların ürün görselleri üzerindeki davranışları evrişimli sinir ağları ile analiz edilerek görsel uyum ve stil benzerlikleri göz önünde bulundurulur. Kullanıcıların ardışık davranışları ise tekrarlayan sinir ağları (RNN) veya Transformer tabanlı modellerle işlenerek daha isabetli kombin önerileri sunulur. Bu yaklaşımların ortak özelliği, ham veri üzerinden yüksek seviyeli temsiller öğrenebilmeleri ve özellik mühendisliği ihtiyacını azaltmalarıdır.

2.2. Aktif Öğrenme ve Geri Bildirim Döngüsü

Modern öneri sistemlerinde kullanıcıya daha iyi ve kişiselleştirilmiş öneriler sunabilmek için yalnızca geçmiş veriler yeterli değildir. Aktif öğrenme yaklaşımı, sistemin kullanıcı etkileşimlerinden öğrenmesini ve öneri politikasını dinamik olarak güncellemesini sağlar (Aggarwal, 2016). Kullanıcı bir kombin önerisini beğendiğinde veya reddettiğinde bu bilgi sistem tarafından anlık olarak işlenir ve gelecekteki öneriler uyarlanır.

Bu süreçte sistem, keşif (exploration) ve kullanım (exploitation) dengesini gözetir. Kullanıcının daha önce sevdiği kombinler sunulurken aynı zamanda yeni kombinler ve stil önerileri test edilerek kullanıcının potansiyel ilgisi keşfedilir. Bu denge, sistemin hem güvenilir hem de yenilikçi öneriler sunmasını mümkün kılar. Literatürde bu denge, çok kollu haydut (multi-armed bandit) algoritmaları ile modellenmekte ve özellikle pekiştirmeli öğrenme tabanlı öneri sistemlerinde merkezi bir rol oynamaktadır.

Geri bildirim döngüsünün etkin biçimde çalışması, sistemin model bozulması (model drift) olgusuna karşı dayanıklılığını da artırmaktadır. Kullanıcı tercihlerinin zaman içinde değişmesi durumunda sistem, yeni etkileşim verilerini hızla işleyerek modelini güncelleyebilir; bu yetenek özellikle sezonluk eğilimlere açık moda ve giyim sektöründe stratejik bir avantaj sağlar.

2.3. Veri Altyapısı ve Frontend Entegrasyonu

Yapay zekâ destekli öneri sistemlerinin başarısı, algoritmaları destekleyen sistem mimarisine ve veri akış altyapısına bağlıdır. Aggarwal (2016), öneri motorlarının üretim ortamına alınmasında veri toplama, model çıkarsama ve ön yüze iletim aşamalarının her birinin gecikme (latency) bütçesi içinde tasarlanması gerektiğini vurgulamaktadır.

Kullanıcı verilerinin API'ler aracılığıyla yapay zekâ modellerine iletilmesi, modellerin ürettiği önerilerin gerçek zamanlı olarak ön yüze aktarılması ve kullanıcı geri bildirimlerinin sisteme beslenmesi bu entegrasyonun temel bileşenlerini oluşturur. RESTful mimarinin durumsuz yapısı, modelin farklı sunucu örnekleri arasında ölçeklenmesine ve yük dengelemesinin verimli biçimde yapılmasına olanak tanımaktadır (Fielding, 2000).

Büyük veri işleme gereksinimleri hem toplu işleme (batch processing) hem de gerçek zamanlı işleme (stream processing) stratejileriyle karşılanır. Toplu işleme, geçmiş verileri analiz ederek model eğitimini optimize ederken; gerçek zamanlı işleme,

kullanıcıya anlık öneriler sunarak kişiselleştirme sürecinin dinamik kalmasını sağlar. Endüstriyel uygulamalarda bu iki yaklaşım çoğunlukla "Lambda mimarisi" altında bir araya getirilir; toplu katman tutarlılığı, hız katmanı ise düşük gecikmeyi sağlar.

2.4. İçerik Tabanlı Filtrelemede TF-IDF ve Vektör Uzayı Modeli

İçerik tabanlı filtrelemede ürünler, sahip oldukları özniteliklere göre vektörlerle temsil edilir. Metinsel özniteliklerin (ürün açıklaması, kategori, etiketler) sayısallaştırılmasında en yaygın yöntemlerden biri Terim Frekansı-Ters Belge Frekansı (TF-IDF) ağırlıklandırmasıdır (Pazzani ve Billsus, 2007). Bu yöntem, bir terimin bir ürün açıklamasında ne sıklıkta geçtiğini, terimin tüm ürünler arasındaki ayırt ediciliğiyle dengeler:

$$a(t, d) = tf(t, d) \times log(N / df(t))$$

Buradaki tf(t, d) terimin ilgili belgedeki frekansını, df(t) terimi içeren belge sayısını ve N toplam belge sayısını ifade eder. Sık geçen ancak ayırt ediciliği düşük terimler (örneğin "ürün", "yeni") düşük ağırlık alırken; belirli ürünlere özgü terimler yüksek ağırlık kazanır. Ürünler bu şekilde vektörlere dönüştürüldükten sonra, kullanıcının geçmişte etkileşimde bulunduğu ürünlerle olan kosinüs benzerlikleri hesaplanarak en benzer ürünler önerilir (Pazzani ve Billsus, 2007).

İçerik tabanlı yaklaşımın en önemli avantajı, yeni eklenen ürünler için topluluk verisi olmadan da öneri üretebilmesidir. Bu özellik özellikle hızlı ürün döngüsüne sahip moda platformlarında değerlidir. Dezavantajı ise yalnızca kullanıcının geçmişte ilgilendiği ürünlere benzer ürünleri önererek "aşırı uzmanlaşma" (overspecialization) sorununa yol açabilmesi ve kullanıcıya çeşitlilik sunmakta zorlanmasıdır (Ricci vd., 2015). Bu sınırlılık, hibrit yaklaşımlarla işbirlikçi filtreleme bileşeninin sürece dâhil edilmesiyle aşılabilmektedir (Burke, 2002).

2.5. İşbirlikçi Filtrelemede k-En Yakın Komşu Yaklaşımı

İşbirlikçi filtrelemenin klasik uygulaması, k-en yakın komşu (k-NN) algoritmasına dayanır (Su ve Khoshgoftaar, 2009). Kullanıcı tabanlı yaklaşımda, hedef kullanıcıya en benzer k adet kullanıcı belirlenir ve bu komşuların puanlarının ağırlıklı ortalaması alınarak tahmin üretilir:

$$\hat{r}_{ui} = \bar{r}_u + (\Sigma \, benzerlik(u, v) \cdot (r_{vi} - \bar{r}_v)) / \Sigma \, |benzerlik(u, v)|$$

Ağırlıklar, komşuların hedef kullanıcıya olan benzerlik derecesiyle orantılıdır. Ancak kullanıcı sayısının ürün sayısından çok daha hızlı artması, kullanıcı tabanlı yaklaşımın ölçeklenebilirliğini sınırlandırmaktadır. Bu sorun, büyük ölçekli e-ticaret platformlarında özellikle belirgin hâle gelmektedir.

Bu sınırlamayı aşmak için Sarwar vd. (2001) tarafından öğe tabanlı işbirlikçi filtreleme geliştirilmiştir. Bu yaklaşımda kullanıcılar yerine ürünler arasındaki benzerlikler önceden hesaplanır; ürün-ürün benzerlik matrisi görece kararlı olduğundan çevrim dışı olarak hesaplanabilir ve çevrim içi öneri süreci hızlanır. Amazon'un öneri motorunda hayata geçirilen öğeden öğeye yaklaşım, bu paradigmanın endüstriyel ölçekte uygulanabilirliğini açıkça göstermiştir (Linden vd., 2003). MODAICA platformunda biriken favori ve sipariş verileri, ileride bu türden bir öğe-öğe benzerlik matrisinin oluşturulması için uygun bir veri kaynağı niteliğindedir.

İşbirlikçi filtrelemenin temel zorlukları veri seyrekliği (sparsity) ve soğuk başlamadır. Kullanıcı-ürün matrisindeki hücrelerin büyük çoğunluğu boş olduğundan, benzerlik hesapları sınırlı veriyle yapılmak zorunda kalır. Bu sorun, matris çarpanlarına ayırma gibi gizli faktör modelleriyle (Koren vd., 2009) veya içerik tabanlı yöntemlerle birleştirilen hibrit yaklaşımlarla (Burke, 2002) hafifletilmektedir.

2.6. Derin Öğrenme Tabanlı Öneri Modelleri

Son yıllarda öneri sistemlerinde derin öğrenme tabanlı yaklaşımlar önemli bir yer edinmiştir. Zhang vd. (2019) tarafından yapılan ayrıntılı derleme, derin öğrenme tabanlı öneri sistemlerinin alanın baskın paradigması hâline geldiğini ve farklı veri tipleriyle çalışabilen esnek bir araç seti sunduğunu göstermektedir.

Sinirsel İşbirlikçi Filtreleme (Neural Collaborative Filtering, NCF) yöntemi, kullanıcı ve ürün arasındaki etkileşimi doğrusal bir iç çarpım yerine çok katmanlı yapay sinir ağlarıyla modelleyerek doğrusal olmayan ilişkileri yakalamayı amaçlar (He vd., 2017). Bu yaklaşım, gizli faktör modellerinin ifade gücünü artırarak daha karmaşık tercih örüntülerinin öğrenilmesine olanak tanır. NCF mimarisinde kullanıcı ve ürün gömülümleri (embeddings) ortak bir gizli uzayda öğrenilir ve bu gömülümler tam bağlantılı katmanlardan geçirilerek etkileşim puanı tahmin edilir.

Kullanıcıların ardışık davranışlarının modellenmesinde ise tekrarlayan sinir ağları (RNN) ve özellikle Uzun Kısa Süreli Bellek (LSTM) birimleri kullanılmaktadır. LSTM,

uzun dizilerdeki bağımlılıkları öğrenebilme yeteneğiyle, kullanıcının oturum içi gezinme ve satın alma sırasını dikkate alan oturum tabanlı önerilerde etkili sonuçlar vermektedir (Hochreiter ve Schmidhuber, 1997). Görsel ağırlıklı moda platformlarında ise evrişimli sinir ağları (CNN), ürün görsellerinden öznitelik çıkararak görsel benzerliğe dayalı öneriler üretir (McAuley vd., 2015).

Derin öğrenme modellerinin başlıca dezavantajı, yüksek hesaplama maliyeti ve büyük miktarda etiketli veriye duyulan ihtiyaçtır. Ayrıca bu modellerin karar mekanizmalarının yorumlanması güç olduğundan, açıklanabilir yapay zekâ yaklaşımlarıyla desteklenmeleri önem kazanmaktadır (Zhang vd., 2019). Bu nedenle pratik sistemlerde derin öğrenme modelleri çoğunlukla geleneksel yöntemlerle birlikte hibrit biçimde kullanılır.

2.7. Bölüm Değerlendirmesi

Bu bölümde incelenen yapay zekâ ve makine öğrenmesi algoritmaları, özellikle e-ticaret ve moda platformlarında kişiselleştirilmiş öneri sistemlerinin temelini oluşturmaktadır. İçerik tabanlı filtreleme yöntemleri kullanıcıya ait geçmiş veri olmadan bile öneri sunabilme avantajı sağlarken; işbirlikçi filtreleme, yeterli veri biriktiğinde daha isabetli ve çeşitli öneriler üretmektedir. Derin öğrenme tabanlı mimariler ise görsel veriler ve bağlamsal etkileşimleri işleyerek öneri sistemlerinin doğruluğunu artırmaktadır.

MODAICA projesi bağlamında değerlendirildiğinde, sistemin mevcut veri altyapısı içerik tabanlı ve örtük geri bildirimli işbirlikçi filtreleme yaklaşımlarının her ikisi için de uygun bir başlangıç noktası sunmaktadır. Bir sonraki bölümde, bu kuramsal çerçevenin MODAICA platformunun pratik uygulamasında nasıl yansıtıldığı ele alınacaktır.

ÜÇÜNCÜ BÖLÜM

PROJE UYGULAMASI

3.1. Proje Genel Tanımı ve Kapsam

Bu çalışmanın pratik boyutunu oluşturan MODAICA projesi, literatürde incelenen yapay zekâ ve e-ticaret sistemleri prensiplerinin gerçek bir uygulama üzerinde hayata geçirilmesini kapsamaktadır. Proje; tam işlevli bir e-ticaret sitesinin frontend, backend ve veritabanı katmanlarını içermektedir.

MODAICA; moda, elektronik ve kozmetik kategorilerinde ürün satışı yapan, Türkçe arayüze sahip, hem masaüstü hem de mobil uyumlu bir e-ticaret platformudur. Siteye ait tüm sayfalar HTML, CSS ve JavaScript ile geliştirilmiş; backend tarafı ise PHP 8.1 ve MySQL ile oluşturulmuştur. Mimari kararlar alınırken Fielding'in (2000) REST mimari ilkeleri rehber olarak alınmış; sistem, durumsuz ve katmanlı bir biçimde tasarlanmıştır.

Projenin genel kapsamı şu başlıkları içermektedir:

- Tam işlevli e-ticaret ön yüzü (ana sayfa, ürün listeleme, hesap yönetimi).
- PHP ve RESTful API tabanlı backend mimarisi.
- JWT ile güvenli kimlik doğrulama sistemi.
- MySQL veritabanı tasarımı (kullanıcılar, siparişler, favoriler, adresler).
- Hem web hem de gelecekte eklenecek mobil uygulamaya aynı backend üzerinden hizmet verme kapasitesi.
- İleride entegre edilecek öneri modülünün ihtiyaç duyacağı kullanıcı-ürün etkileşim verilerinin toplanması.

3.2. Frontend Geliştirme

Projenin ön yüzü tamamen sıfırdan geliştirilmiş olup herhangi bir CSS veya JavaScript çerçevesine bağımlılık olmaksızın yazılmıştır. Bu tercih, hem öğrenme hedefleri açısından hem de bağımlılık yönetiminin sadeleştirilmesi açısından bilinçli olarak yapılmıştır. Sayfalar arası tutarlılık CSS değişkenleri aracılığıyla sağlanmıştır.

Ana Sayfa: Ana sayfa; üç farklı kategoride otomatik geçişli kaydırmalı slider'lar, altı ana kategori için ızgara görünümü, sekiz ürünlük popüler ürünler bölümü, kampanya

banner'ları, marka listesi, bülten aboneliği formu ve tam footer içermektedir. Her slider kendi temasına uygun renk paleti ve kayan bilgi kartlarıyla tasarlanmıştır.

Hesabım Sayfası: Hesabım sayfası; giriş yapılmamış kullanıcılar için kayıt ve giriş ekranı, giriş yapmış kullanıcılar için ise tam hesap paneli sunmaktadır. Hesap paneli sekiz farklı bölümden oluşmaktadır:

- **Hesap Özeti:** Toplam sipariş, kargodaki ürün, favori sayısı ve puan bakiyesi istatistikleri.
- **Profil Bilgilerim:** Ad-soyad, e-posta, telefon ve cinsiyet gibi bilgilerin düzenlenmesi.
- **Siparişlerim:** Tüm siparişlerin duruma göre filtrelenmesi.
- **Favorilerim:** Favoriye eklenen ürünlerin listelenmesi ve yönetimi.
- **Adreslerim:** Kayıtlı teslimat adreslerinin yönetimi.
- **Güvenlik:** Şifre değiştirme ve iki faktörlü doğrulama ayarları.
- **Bildirimler:** E-posta, SMS ve push bildirim tercihlerinin yönetimi.
- **Sadakat Puanları:** Puan bakiyesi ve üyelik seviyesi bilgisi.

Favoriler ve Sepet Sayfaları: Favoriler sayfası, giriş yapılmamış kullanıcılara doğrudan yönlendirme göstermektedir. Kategori filtre butonları, sıralama seçenekleri ve grid/liste görünümü geçişi sunar. Sepet sayfası ise ürün adet kontrolü, kargo seçenekleri, kupon kodu uygulaması ve dinamik sipariş özeti içermektedir.

3.3. Backend ve API Mimarisi

Projenin backend tarafı PHP 8.1 ile yazılmış olup RESTful API mimarisini benimsemektedir. Bu mimari, hem web uygulamasının hem de gelecekte geliştirilecek mobil uygulamanın aynı backend'e bağlanabilmesine olanak tanır. Mimarinin durumsuz yapısı, her isteğin kendi kimlik doğrulama ve içerik bilgisini taşımasını gerektirdiğinden, sistem yatay ölçeklenmeye uygun hâle gelmektedir (Fielding, 2000).

Backend klasör yapısı dört ana bileşenden oluşmaktadır:

- **config/ klasörü:** Veritabanı bağlantısı, uygulama ayarları ve veritabanı şeması.
- **helpers/ klasörü:** JWT üretme ve doğrulama, JSON yanıt yardımcıları ve doğrulama fonksiyonları.

- **middleware/ klasörü:** Korumalı route'lar için JWT kontrolü.
- **api/ klasörü:** Kimlik doğrulama, profil, siparişler, favoriler, adresler, puanlar ve ayarlar için ayrı PHP dosyaları.

Geliştirilen API uç noktaları şu işlevleri kapsamaktadır:

- **auth.php:** Kayıt (POST), giriş (POST) ve mevcut kullanıcı bilgisi alma (GET) işlemleri.
- **profile.php:** Profil görüntüleme, güncelleme, şifre değiştirme ve avatar yükleme.
- **orders.php:** Sipariş listeleme, detay görüntüleme ve iptal etme.
- **favorites.php:** Favori listeleme, ekleme ve kaldırma.
- **addresses.php:** Adres yönetimi (listeleme, ekleme, güncelleme, silme).
- **points.php:** Puan bakiyesi ve geçmişi.
- **settings.php:** Bildirim tercihleri ve güvenlik ayarları.

3.4. Veritabanı Tasarımı

Proje MySQL veritabanı kullanmakta olup sekiz farklı tablo içermektedir. Tüm tablolar utf8mb4 karakter seti ile oluşturulmuş; Türkçe karakter desteği sağlanmıştır. Veritabanı tasarımında üçüncü normal forma (3NF) kadar normalizasyon uygulanmış; veri tekrarı ve güncelleme anomalileri en aza indirilmiştir.

Veritabanı tabloları ve işlevleri:

- **users:** Kullanıcı kimlik bilgileri, profil verileri, üyelik seviyesi ve puan bakiyesi.
- **addresses:** Kullanıcılara ait teslimat adresleri; varsayılan adres belirleme desteği.
- **orders:** Sipariş kodları, durumlar ve toplam tutarlar.
- **order_items:** Sipariş kalemlerinin ürün adı, fiyatı ve adedi.
- **favorites:** Kullanıcıların favoriye eklediği ürünler.
- **points_log:** Puan kazanma ve harcama işlemlerinin geçmişi.
- **notification_prefs:** E-posta, SMS ve push bildirim tercihleri.
- **security_settings:** İki faktörlü doğrulama ve giriş bildirim ayarları.

3.5. Güvenlik ve Kimlik Doğrulama

Projenin güvenlik katmanı JWT tabanlı kimlik doğrulama üzerine inşa edilmiştir. Kullanıcı başarıyla giriş yaptığında sistem, yedi gün geçerli bir token üretir. Bu token sonraki tüm API isteklerinde Authorization başlığında gönderilir ve middleware tarafından doğrulanır. JWT'nin tercih edilmesinin temel nedeni, durumsuz REST mimarisiyle doğal uyum içinde olmasıdır: sunucu tarafında oturum bilgisi tutmaya gerek kalmaz.

Uygulanan güvenlik önlemleri şunlardır:

- **Şifre Hashleme:** Tüm kullanıcı şifreleri bcrypt algoritmasıyla hashlenip veritabanına kaydedilmektedir. Şifreler asla düz metin olarak saklanmaz. Bcrypt'in adaptif yapısı, donanım performansı arttıkça parola kırma maliyetinin de orantılı olarak yükseltilebilmesini sağlar.
- **SQL Injection Koruması:** Tüm veritabanı sorguları PDO prepared statement ile yazılmıştır. Bu yaklaşım, kullanıcı girdisinin sorgu yapısına karışmasını engelleyerek enjeksiyon saldırılarına karşı katmanlı koruma sağlar.
- **CORS Yönetimi:** Yalnızca yetkili kaynakların API'ye erişimine izin verilmektedir. İzin verilen kaynaklar config/app.php dosyasında merkezi olarak tanımlanmıştır.
- **Token Doğrulama:** Her korumalı endpoint, gelen token'ı middleware aracılığıyla doğrular; geçersiz veya süresi dolmuş token'larda 401 yanıt döner.
- **Şifre Politikası:** Kullanıcı kaydı sırasında en az 8 karakter uzunluğunda, harf ve rakam içeren şifre zorunluluğu sağlanmaktadır.

3.6. Veritabanı İlişkileri ve Normalizasyon

MODAICA veritabanı, ilişkisel veritabanı tasarım ilkeleri doğrultusunda normalize edilmiştir. Tablolar arasındaki ilişkiler yabancı anahtarlar (foreign key) aracılığıyla kurulmuş; veri tekrarının önlenmesi ve bütünlüğün korunması hedeflenmiştir. Merkezde yer alan users tablosu, diğer tabloların büyük bölümüyle bire-çok ilişki içindedir.

Tablolar arasındaki başlıca ilişkiler şu şekildedir:

- **users — addresses:** Bir kullanıcının birden çok teslimat adresi olabilir (bire-çok). addresses tablosundaki user_id alanı users tablosuna bağlanır.

- **users — orders:** Bir kullanıcının birden çok siparişi bulunabilir; her sipariş tek bir kullanıcıya aittir.
- **orders — order_items:** Bir sipariş birden çok kalem içerebilir. Bu yapı sipariş ile ürün kalemlerinin ayrı tablolarda tutulmasını sağlayarak normalizasyonu güçlendirir.
- **users — favorites:** Kullanıcı ile favori ürünler arasında çoka-çok ilişkiyi çözen bir ara tablo görevi görür.

Veri bütünlüğünü korumak amacıyla silme ve güncelleme işlemlerinde ilişkisel kısıtlar (ON DELETE CASCADE, ON UPDATE CASCADE) tanımlanmıştır. Örneğin bir kullanıcı silindiğinde, ona bağlı adres ve favori kayıtlarının da tutarlı biçimde yönetilmesi sağlanır. Bu tasarım, ileride öneri modülünün ihtiyaç duyacağı kullanıcı-ürün etkileşim verilerinin temiz ve ilişkisel bir biçimde elde edilmesine zemin hazırlamaktadır.

3.7. Kişiselleştirme Modülünün Sisteme Entegrasyon Planı

MODAICA, mevcut hâliyle öneri sisteminin ihtiyaç duyduğu veri altyapısını üretecek biçimde tasarlanmıştır. Kullanıcıların favori ekleme, sipariş verme ve ürün görüntüleme davranışları veritabanında izlenebilir durumdadır. Bu davranış verileri, işbirlikçi filtreleme modellerinin temel girdisi olan kullanıcı-ürün etkileşim matrisinin oluşturulmasında doğrudan kullanılabilir (Sarwar vd., 2001; Hu vd., 2008).

Planlanan entegrasyonda öneri modülü, mevcut RESTful API mimarisine yeni bir uç nokta (örneğin /api/recommendations.php) olarak eklenecektir. Bu uç nokta, kullanıcının kimliğine göre çevrim dışı eğitilmiş modelden üretilen öneri listesini JSON formatında döndürecektir. Modelin eğitimi, sunucu yükünü artırmamak için belirli aralıklarla çalışan toplu işlerle (batch job) çevrim dışı olarak gerçekleştirilecektir.

Soğuk başlama problemini hafifletmek için sisteme katmanlı bir strateji önerilmektedir: yeni kullanıcılara öncelikle popülerlik tabanlı ve içerik tabanlı öneriler sunulacak; kullanıcı yeterli etkileşim verisi ürettikçe sistem işbirlikçi filtreleme ve gizli faktör modellerine geçiş yapacaktır. Bu hibrit yaklaşım, literatürde önerilen kombinasyon stratejileriyle uyumludur (Burke, 2002; Ricci vd., 2015).

3.8. Sonuçlar ve Değerlendirme

MODAICA projesi, e-ticaret sistemlerinde yapay zekâ entegrasyonunun temellerini atan, ölçeklenebilir ve genişletilebilir bir altyapıyla hayata geçirilmiştir. Tüm bileşenler birbirinden bağımsız ancak uyumlu çalışacak şekilde tasarlanmıştır. Frontend değiştirilmeden backend güncellenebilir; farklı bir frontend (örneğin React veya Vue.js) aynı backend API'lerine bağlanabilir.

Projenin başarıyla tamamlanan çıktıları:

- Üç farklı kategoride slider içeren, tam duyarlı ana sayfa tasarımı.
- JWT tabanlı kimlik doğrulama sistemi; kayıt, giriş ve oturum yönetimi.
- Sekiz farklı bölümden oluşan, tam işlevli hesap yönetim paneli.
- Kategori filtresi ve sıralama özellikli favoriler sayfası.
- Kargo seçenekleri, kupon kodu ve sipariş özeti içeren sepet sayfası.
- PHP ve MySQL tabanlı RESTful API altyapısı.
- Üçüncü normal forma uygun, sekiz tablolu ilişkisel veritabanı şeması.

3.9. Gelecek Çalışmalar ve Öneriler

Bu çalışma kapsamında geliştirilen MODAICA projesi, ilerleyen süreçte birçok yeni özellikle genişletilmesi planlanmaktadır. Öncelikli olarak yapay zekâ destekli kombin öneri sistemi entegre edilecektir. Bu modülün ilk sürümünde içerik tabanlı yaklaşım ve popülerlik tabanlı geçici öneriler bir arada kullanılacak; veri biriktikçe öğe tabanlı işbirlikçi filtrelemeye geçiş yapılacaktır.

Planlanan diğer geliştirmeler şunlardır:

- React Native ile iOS ve Android için mobil uygulama geliştirilmesi; mevcut PHP backend'in değiştirilmeden kullanılması.
- Gerçek ödeme altyapısı entegrasyonu (iyzico, PayTR veya Stripe gibi ödeme sağlayıcıları).
- Ürün ve sipariş yönetimi için admin paneli.
- Bulut sunucusuna geçiş ve HTTPS yapılandırması.
- Açıklanabilir yapay zekâ bileşeni ile kullanıcıya "Bu ürün neden önerildi?" açıklaması sunulması.

- KVKK uyumluluğunu güçlendiren açık rıza ve veri silme akışlarının uygulanması.
- Redis tabanlı oturum ve öneri önbellekleme katmanı eklenmesi.

DÖRDÜNCÜ BÖLÜM

SİSTEM TASARIMI VE MİMARİ DETAYLAR

4.1. Yazılım Geliştirme Süreci

MODAICA projesi çevik (agile) geliştirme anlayışı benimsenerek aşamalı biçimde oluşturulmuştur. İlk aşamada kullanıcı deneyimi tasarımı ve prototip çalışmaları yapılmış; ardından frontend bileşenleri, backend altyapısı ve veritabanı katmanı sırasıyla geliştirilmiştir. Süreç boyunca her bileşenin diğer bileşenlerden bağımsız çalışabilir olmasına özen gösterilmiştir.

Geliştirme ortamı olarak Windows işletim sistemi üzerinde XAMPP kullanılmıştır. XAMPP; Apache web sunucusu, MySQL veritabanı ve PHP yorumlayıcısını tek bir paket hâlinde sunmaktadır. Bu yapı geliştirme sürecini önemli ölçüde hızlandırmış; yerel ortamda hızlı iterasyon olanağı sağlamıştır.

Sürüm kontrolü için Git kullanılmış ve proje GitHub üzerinde özel bir depoda barındırılmıştır. Geliştirme dalları (feature branches) üzerinden yapılan değişiklikler, ana dala (main) birleştirilmeden önce ekip üyeleri tarafından gözden geçirilmiştir. Bu süreç hem kod kalitesini hem de ekip içi bilgi paylaşımını desteklemiştir.

4.2. Kullanıcı Arayüzü Tasarım Kararları

Sitenin görsel kimliği oluşturulurken üç temel renk belirlenmiştir: lacivert (#1a1f5e) ana renk, kırmızı (#e63946) vurgu rengi ve altın sarısı (#f4a226) ikincil vurgu rengi olarak kullanılmaktadır. Bu renkler CSS değişkenleri aracılığıyla tanımlanmış; tüm sayfalarda tutarlı biçimde uygulanmıştır. CSS değişkenleri kullanımı, ileride tema değişikliği veya karanlık mod desteği eklenmesini de kolaylaştırmaktadır.

Tipografi açısından başlıklarda Playfair Display serif fontu, gövde metninde ise DM Sans sans-serif fontu tercih edilmiştir. Serif ve sans-serif fontların birlikte kullanımı, sitenin moda ve elektronik gibi farklı kategorilerin her birine uygun düşen, modern ama prestijli bir görünüm kazanmasını sağlamıştır. Sayfa düzeni CSS Grid ve Flexbox teknolojileri kullanılarak oluşturulmuştur. Duyarlı tasarım için medya sorguları kullanılmış; sayfalar 480px, 768px ve 1100px kırılma noktalarında farklı düzenler sunmaktadır.

4.3. API Tasarım Prensipleri

Projenin API'leri RESTful prensipler doğrultusunda tasarlanmıştır (Fielding, 2000). Her kaynak için tutarlı URL yapısı kullanılmış; HTTP metotları anlam bütünlüğü içinde uygulanmıştır. Tüm yanıtlar JSON formatında döndürülmekte ve success, message, data alanlarını içeren standart bir yapı izlenmektedir.

HTTP durum kodları standartlara uygun olarak kullanılmıştır. Başarılı işlemler için 200, kaynak oluşturulduğunda 201, kimlik doğrulama hatalarında 401, yetkilendirme hatalarında 403, kaynak bulunamadığında 404, validasyon hatalarında 422 ve sunucu hatalarında 500 döndürülmektedir. Bu tutarlı kullanım, hem ön yüz tarafında hata yönetiminin sadeleşmesini hem de gelecekte eklenecek mobil uygulamanın aynı sözleşmeyi kullanabilmesini sağlar.

4.4. Performans Optimizasyonu

Frontend performansı açısından görüntüler Intersection Observer API ile tembel yükleme (lazy loading) yöntemiyle yüklenmektedir. Animasyonlar CSS transform ve opacity özellikleri üzerinden yapılmakta; bu sayede tarayıcının GPU hızlandırmasından yararlanılmaktadır. JavaScript dosyaları sayfa sonuna alınarak ilk içerik boyama (First Contentful Paint) süresi kısaltılmıştır.

Backend performansı açısından veritabanı sorguları hazırlanmış ifadeler (prepared statements) ile yapılmakta; PDO singleton deseni kullanılarak her istek için tek bir veritabanı bağlantısı oluşturulmaktadır. Bu yaklaşım gereksiz bağlantı açma-kapama maliyetinden kaçınmayı sağlar. Sık erişilen kullanıcı verileri için ileride Redis tabanlı bir önbellek katmanı eklenmesi planlanmaktadır.

4.5. Test ve Doğrulama Süreci

Projenin test sürecinde her API uç noktası phpMyAdmin veritabanı arayüzü ve tarayıcı geliştirici araçları kullanılarak doğrulanmıştır. Postman aracılığıyla API uç noktalarının manuel testleri yapılmış; yanıt yapıları, durum kodları ve zaman aşımı davranışları incelenmiştir. Frontend bileşenleri Chrome, Firefox ve Edge tarayıcılarında test edilmiş; duyarlı tasarım davranışı farklı ekran boyutlarında kontrol edilmiştir.

Kullanıcı kayıt ve giriş akışı test edilirken şu senaryolar ele alınmıştır: geçerli kayıt işlemi, daha önce kayıtlı e-posta adresiyle kayıt denemesi, yanlış şifre ile giriş denemesi, süresi dolmuş token ile işlem yapma ve yetkisiz kaynaklara erişim denemesi.

Her senaryoda beklenen davranışın gerçekleştiği gözlemlenmiş; aksaklık tespit edilen durumlarda kod düzeyinde düzeltmeler yapılarak testler yinelenmiştir.

4.6. Projenin Literatürle İlişkisi

Bu çalışmada geliştirilen MODAICA projesi, literatürde incelenen kavramların somut bir uygulama hâline getirilmesini temsil etmektedir. Kullanıcı davranış verilerinin toplanması, sipariş geçmişi ve favori listelerinin takip edilmesi açısından sistem, işbirlikçi filtreleme modellerinin ihtiyaç duyduğu temel veri kaynaklarını zaten üretmektedir (Sarwar vd., 2001; Linden vd., 2003).

Sistem mimarisi açısından literatürde vurgulanan üç katmanlı yapı bu projede de uygulanmıştır (Aggarwal, 2016). Veri katmanı MySQL veritabanı, uygulama katmanı PHP API'leri ve JavaScript ön yüzünden oluşmaktadır. Model katmanı ise yapay zekâ entegrasyonu yapılacağında mevcut API yapısına kolayca eklenebilecek biçimde tasarlanmıştır. Bu katmanlı yaklaşım, hem değişikliklerin etkilerinin sınırlandırılmasına hem de bileşenlerin bağımsız ölçeklenmesine imkân tanımaktadır (Fielding, 2000).

4.7. Karşılaşılan Güçlükler ve Çözüm Yolları

Proje sürecinde karşılaşılan en önemli teknik güçlük, PHP backend ile JavaScript ön yüzü arasındaki iletişimin CORS politikaları nedeniyle engellenmesiydi. Sorun, config/app.php dosyasında izin verilen kaynaklar listesinin doğru biçimde tanımlanması ve her PHP dosyasının başında setCORSHeaders() fonksiyonunun çağrılmasıyla çözülmüştür. Bu deneyim, ön uç ve arka uç ayrımının net olduğu modern web uygulamalarında CORS yapılandırmasının başlangıçta planlanması gerektiğini açıkça göstermiştir.

Kullanıcı oturumunun sayfa yenilemelerinde korunması için localStorage tabanlı token saklama yaklaşımı benimsenmiştir. Veritabanı bağlantı yönetimi açısından singleton tasarım deseni uygulanmıştır. Türkçe karakter sorunu ise veritabanının utf8mb4 karakter seti ve PHP kodlarında UTF-8 başlığı belirtilmesiyle çözülmüştür. Ayrıca tarayıcılar arası tutarsızlıklar (özellikle eski Safari sürümlerinde CSS Grid davranışı) progressive enhancement yaklaşımıyla ele alınmıştır.

4.8. Ölçeklenebilirlik ve Önbellekleme Stratejileri

E-ticaret platformlarının kullanıcı sayısı arttıkça, sistem yanıt süresinin kabul edilebilir sınırlar içinde kalması kritik önem taşır. MODAICA'nın RESTful mimarisi, durumsuz (stateless) tasarım ilkesini benimsediğinden yatay ölçeklenmeye uygundur (Fielding, 2000). Durumsuz tasarımda her API isteği gerekli tüm bilgiyi kendi içinde taşır; böylece istekler birden çok sunucu örneği arasında dağıtılabilir.

Performansı artırmak için önerilen önbellekleme stratejileri arasında sık erişilen ürün listelerinin ve popüler öneri sonuçlarının bellek içi önbellekte (örneğin Redis) tutulması yer almaktadır. Veritabanı düzeyinde ise sık sorgulanan sütunlara dizin (index) eklenmesi sorgu sürelerini önemli ölçüde kısaltır. Öneri sonuçları gibi hesaplama maliyeti yüksek çıktıların çevrim dışı olarak önceden hesaplanıp saklanması, çevrim içi yanıt süresini düşüren etkili bir yöntemdir (Aggarwal, 2016).

Ayrıca içerik dağıtım ağları (CDN) kullanılarak statik varlıkların (resim, CSS, JavaScript) son kullanıcıya en yakın sunucudan iletilmesi sağlanabilir. Veritabanı tarafında okuma yükü arttığında okuma replikalarının (read replicas) kullanılması, yazma işlemlerinden bağımsız bir ölçeklenme yolu sunar.

4.9. Yapay Zekâ Modelinin Dağıtımı ve İzlenmesi

Bir öneri modelinin geliştirilmesi kadar üretim ortamında sürdürülebilir biçimde çalıştırılması da önemlidir. Önerilen mimaride model, ana uygulamadan ayrı bir servis olarak konumlandırılır ve mevcut PHP backend ile API üzerinden haberleşir. Bu ayrıştırma, modelin uygulama kodundan bağımsız olarak güncellenebilmesini sağlar. Zhang vd. (2019), derin öğrenme tabanlı öneri sistemlerinin üretime alınmasında bu tür hizmet odaklı mimari yaklaşımların standart hâle geldiğini belirtmektedir.

Modelin zaman içindeki başarımının izlenmesi, kullanıcı davranışlarının değişmesiyle ortaya çıkan model bozulması (model drift) olgusu nedeniyle gereklidir. Önerilen önerilerin tıklanma ve dönüşüm oranları sürekli izlenerek modelin yeniden eğitilmesi gereken durumlar tespit edilir. Ayrıca açıklanabilir yapay zekâ bileşeniyle, kullanıcılara önerilerin gerekçesi sunularak hem kullanıcı güveni artırılır hem de sistemin şeffaflığı sağlanır. Yaygın izleme ölçütleri arasında çevrim içi tıklama oranı (CTR), dönüşüm oranı, ortalama sepet tutarı ve öneri çeşitliliği sayılabilir (Ricci vd., 2015).

Model güncellemelerinde A/B testi kullanılması, yeni modelin mevcut modele kıyasla gerçek kullanıcılar üzerindeki etkisinin istatistiksel olarak doğrulanmasını sağlar.

Bu yaklaşım, üretime alınan her güncellemenin iş metriklerine olan etkisinin somut biçimde ölçülmesine olanak tanır.

SONUÇ

Bu çalışmada, e-ticaret platformlarında yapay zekâ destekli kişiselleştirme ve öneri sistemleri hem kuramsal hem de uygulamalı boyutlarıyla incelenmiştir. Literatür taraması, öneri sistemlerinin içerik tabanlı, işbirlikçi ve hibrit olmak üzere üç temel yaklaşım etrafında geliştiğini; her yaklaşımın kendine özgü güçlü ve zayıf yönleri bulunduğunu ortaya koymuştur (Adomavicius ve Tuzhilin, 2005; Burke, 2002). İçerik tabanlı yöntemler yeni ürünler için avantaj sağlarken aşırı uzmanlaşmaya eğilimlidir; işbirlikçi filtreleme daha isabetli ve çeşitli öneriler üretmekle birlikte veri seyrekliği ve soğuk başlama sorunlarıyla karşılaşır (Su ve Khoshgoftaar, 2009).

İncelenen kaynaklar, bu sorunların hibrit yaklaşımlar ve gizli faktör modelleriyle hafifletilebildiğini göstermektedir. Özellikle matris çarpanlarına ayırma ve sinirsel işbirlikçi filtreleme gibi yöntemlerin, büyük ölçekli platformlarda klasik en yakın komşu yaklaşımlarına kıyasla daha başarılı sonuçlar verdiği görülmüştür (Koren vd., 2009; He vd., 2017). Derin öğrenme tabanlı modeller yüksek doğruluk sunsa da hesaplama maliyeti ve yorumlanabilirlik açısından sınırlamalar barındırmakta; bu nedenle açıklanabilir yapay zekâ yaklaşımlarıyla desteklenmeleri önem kazanmaktadır (Zhang vd., 2019).

Çalışmanın uygulama boyutunda geliştirilen MODAICA projesi, bu kuramsal çerçevenin somut bir e-ticaret altyapısına nasıl yansıtılabileceğini göstermiştir. Tam işlevli bir ön yüz, PHP tabanlı RESTful API mimarisi, JWT ile güvenli kimlik doğrulama ve normalize edilmiş bir MySQL veritabanı başarıyla geliştirilmiştir. Sistemin katmanlı ve durumsuz mimarisi, hem ölçeklenebilirliği hem de gelecekte eklenecek bir öneri modülünün entegrasyonunu kolaylaştıracak biçimde tasarlanmıştır (Fielding, 2000).

Çalışmanın araştırma sorularına dönüldüğünde; filtreleme yöntemleri arasındaki farklar ortaya konmuş, bilgi aşırı yüklenmesi ve soğuk başlama problemlerine yönelik çözümler tartışılmış ve bu yöntemlerin gerçek bir platforma uyarlanmasının yolu, MODAICA'nın ürettiği etkileşim verileri üzerinden gösterilmiştir. Böylece literatürdeki kavramlar ile uygulama arasında somut bir köprü kurulmuştur.

Sonuç olarak, yapay zekâ destekli kişiselleştirme yalnızca teknik bir iyileştirme değil; kullanıcı memnuniyetini ve platform rekabetçiliğini doğrudan etkileyen stratejik bir unsurdur. Bu çalışmanın hem kavramsal çerçevesi hem de geliştirilen uygulama altyapısı, ileride yapay zekâ tabanlı öneri modüllerinin entegre edileceği daha kapsamlı

sistemler için sağlam bir temel oluşturmaktadır. Gelecek çalışmalarda, MODAICA üzerinde toplanacak gerçek kullanıcı verileriyle bir öneri modelinin eğitilmesi, farklı değerlendirme ölçütleri üzerinden başarımının ölçülmesi ve açıklanabilir yapay zekâ bileşeniyle desteklenmesi planlanmaktadır. Ek olarak, KVKK uyumluluğunu sağlayan veri yönetişimi prosedürlerinin tasarlanması ve hibrit öneri stratejilerinin Türkiye pazarına özgü kullanıcı davranışlarıyla doğrulanması, alana özgün bir akademik ve pratik katkı sunacaktır.

KAYNAKÇA

Akademik Kaynaklar

Adomavicius, G. ve Tuzhilin, A. (2005). Toward the Next Generation of Recommender Systems: A Survey of the State-of-the-Art and Possible Extensions. *IEEE Transactions on Knowledge and Data Engineering*, 17(6), 734-749.

Aggarwal, C. C. (2016). *Recommender Systems: The Textbook*. Springer.

Burke, R. (2002). Hybrid Recommender Systems: Survey and Experiments. *User Modeling and User-Adapted Interaction*, 12(4), 331-370.

Fielding, R. T. (2000). *Architectural Styles and the Design of Network-based Software Architectures* (Doktora tezi). University of California, Irvine.

Goldberg, D., Nichols, D., Oki, B. M. ve Terry, D. (1992). Using Collaborative Filtering to Weave an Information Tapestry. *Communications of the ACM*, 35(12), 61-70.

He, X., Liao, L., Zhang, H., Nie, L., Hu, X. ve Chua, T.-S. (2017). Neural Collaborative Filtering. *Proceedings of the 26th International Conference on World Wide Web (WWW '17)*, 173-182.

Hochreiter, S. ve Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735-1780.

Hu, Y., Koren, Y. ve Volinsky, C. (2008). Collaborative Filtering for Implicit Feedback Datasets. *Proceedings of the 8th IEEE International Conference on Data Mining (ICDM '08)*, 263-272.

Koren, Y., Bell, R. ve Volinsky, C. (2009). Matrix Factorization Techniques for Recommender Systems. *Computer*, 42(8), 30-37.

Linden, G., Smith, B. ve York, J. (2003). Amazon.com Recommendations: Item-to-Item Collaborative Filtering. *IEEE Internet Computing*, 7(1), 76-80.

McAuley, J., Targett, C., Shi, Q. ve van den Hengel, A. (2015). Image-Based Recommendations on Styles and Substitutes. *Proceedings of the 38th International*

ACM SIGIR Conference on Research and Development in Information Retrieval, 43-52.

Pazzani, M. J. ve Billsus, D. (2007). Content-Based Recommendation Systems. *The Adaptive Web (Lecture Notes in Computer Science, Cilt 4321)*, 325-341. Springer.

Resnick, P. ve Varian, H. R. (1997). Recommender Systems. *Communications of the ACM*, 40(3), 56-58.

Ricci, F., Rokach, L. ve Shapira, B. (2015). *Recommender Systems Handbook* (2. baskı). Springer.

Sarwar, B., Karypis, G., Konstan, J. ve Riedl, J. (2001). Item-Based Collaborative Filtering Recommendation Algorithms. *Proceedings of the 10th International Conference on World Wide Web (WWW '01)*, 285-295.

Schafer, J. B., Konstan, J. A. ve Riedl, J. (1999). Recommender Systems in E-Commerce. *Proceedings of the 1st ACM Conference on Electronic Commerce (EC '99)*, 158-166.

Su, X. ve Khoshgoftaar, T. M. (2009). A Survey of Collaborative Filtering Techniques. *Advances in Artificial Intelligence*, 2009, 1-19.

Zhang, S., Yao, L., Sun, A. ve Tay, Y. (2019). Deep Learning Based Recommender System: A Survey and New Perspectives. *ACM Computing Surveys*, 52(1), 1-38.

Web Siteleri ve Araçlar

Anthropic. (t.y.). *Claude Yapay Zekâ Asistanı*. https://claude.ai (Erişim tarihi: 15.06.2026). Resmî yazı stillerinde, kod hatalarının giderilmesinde ve API entegrasyonu sırasında yardımcı olarak kullanılmıştır.

Apache Friends. (t.y.). *XAMPP Geliştirme Ortamı*. https://www.apachefriends.org (Erişim tarihi: 15.06.2026). Yerel geliştirme ortamı olarak kullanılmıştır.

Google Fonts. (t.y.). *DM Sans ve Playfair Display Fontları*. https://fonts.google.com (Erişim tarihi: 15.06.2026). Sitenin tipografisi için kullanılmıştır.

Mozilla Developer Network. (t.y.). *HTML, CSS ve JavaScript Dokümantasyonu*. https://developer.mozilla.org (Erişim tarihi: 15.06.2026). Frontend geliştirme sürecinde referans olarak başvurulmuştur.

MySQL. (t.y.). *MySQL 8.0 Referans Kılavuzu*. https://dev.mysql.com/doc (Erişim tarihi: 15.06.2026). Veritabanı tasarımı ve sorgu geliştirme sürecinde kullanılmıştır.

Node.js. (t.y.). *Node.js v22 Dokümantasyonu*. https://nodejs.org (Erişim tarihi: 15.06.2026). JavaScript çalışma ortamı olarak kullanılmıştır.

npm. (t.y.). *docx Paketi (v9.5.3)*. https://www.npmjs.com/package/docx (Erişim tarihi: 15.06.2026). Word belgesi oluşturmak için kullanılmıştır.

PHP. (t.y.). *PHP 8.1 Resmî Dokümantasyonu*. https://www.php.net/manual (Erişim tarihi: 15.06.2026). Backend API geliştirme sürecinde referans olarak kullanılmıştır.

Görsel Kaynaklar

Pexels. (t.y.). *Ücretsiz Stok Fotoğraflar*. https://pexels.com (Erişim tarihi: 15.06.2026). Ürün görselleri için kullanılmıştır.

Unsplash. (t.y.). *Ücretsiz Stok Fotoğraflar*. https://unsplash.com (Erişim tarihi: 15.06.2026). Sitenin slider ve ürün görselleri için faydalanılmıştır.